МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Компьютерные науки и прикладная математика» Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №2 по курсу «Параллельная обработка данных»

Работа с матрицам. Метод Гаусса.

Выполнил: В.В. Бирюков

Группа: 8О-407Б

Преподаватель: А.Ю. Морозов

Условие

Цель работы: Использование объединения запросов к глобальной памяти. Реализация метода Гаусса с выбором главного элемента по столбцу. Ознакомление с библиотекой алгоритмов для параллельных расчетов Thrust.

Вариант: 3. Решение квадратной СЛАУ.

Программное и аппаратное обеспечение

Характеристики графического процессора:

• Наименование: GeForce GT 545

• Compute capability: 2.1

Графическая память: 3150381056 Б
Разделяемая память на блок: 49152 Б

• Количество регистров на блок: 32768

• Максимальное количество потоков на блок: (1024, 1024, 64)

• Максимальное количество блоков: (65535, 65535, 65535)

• Константная память: 65536 Б

• Количество мультипроцессоров: 3

Характеристики системы:

• Процессор: Intel(R) Core(TM) i7-3770 CPU 3.40GHz

Память: 15 ГБHDD: 500 ГБ

Программное обеспечение:

• OC: Ubuntu 16.04.6 LTS

• IDE: Visual Studio Code 1.72

• Компилятор: nvcc 7.5.17

Метод решения

Для решения квадратной СЛАУ необходимо привести матрицу системы к верхнетреугольному виду, при помощи прямого хода метода Гаусса, затем найти решение обратным ходом (x_n тривиально находится из единственного элемента последней строки, x_{n-1} через x_n и так далее).

Один шаг метода Гаусса состоит из нескольких этапов: выделение ведущего элемента (максимального в столбце), перестановка строки с ведущим элементом на первое место для данного шага, зануление текущего столбца. Суммарно необходимо выполнить n шагов.

Сложность прямого хода — $O(n^3)$, обратного — $O(n^2)$. Итого — $O(n^3)$.

Описание программы

В файле lab4. cu расположен основной код программы. Функция gaussian_solver_step — вычислительное ядро — осуществляет финальный этап шага метода Гаусса. Функция swap_rows — другое ядро — переставляет местами две строки матрицы. Максимальный элемент столбца находится при помощи функции thrust::max_element. Таким образом весь прямой ход метода Гаусса осуществляется над матрицей в видеопамяти. Обратный ход не распараллеливается, так как его сложность значительно меньше, и целиком выполняется на CPU.

Результаты

Анализ программы профилировщиком

Конфигурация ядра: 32×32 , 32×32 ; размер тестовой матрицы: 2000×2000 . Из вывода nvprof убраны нечитаемые названия ядер thrust.

В ядре gaussian_solver_step потоки варпа обрабатывают столбцы матрицы:

Invocations	Event Name		Max	Avg
Device "GeForce	GT 545 (0)"			
Kernel:	<pre>gaussian_solver_step(double*, int, int)</pre>			
2000	${\tt global_store_transaction}$	0	500208	161671
Kernel:	<pre>swap_rows(double*, int, int, int)</pre>			
1994	${\tt global_store_transaction}$	6144	6144	6144

В ядре gaussian_solver_step потоки варпа обрабатывают строки матрицы:

Invocations	Event Name	Min	Max	Avg
Device "GeForce	GT 545 (0)"			
Kernel:	<pre>gaussian_solver_step(double*, int, int)</pre>			
2000	${\tt global_store_transaction}$	0	4002432	1335062
Kernel:	<pre>swap_rows(double*, int, int, int)</pre>			
1994	<pre>global_store_transaction</pre>	6144	6144	6144

Видно, что во втором случае происходит гораздо больше обращений к глобальной памяти, т.е. объединения запросов не происходит. На практике это приводит к увеличению времени работы в 2-3 раза.

Сравнение времени работы

Размер матрицы	100	500	1000	2000	5000	10000
Конфигурация	Время выполнения, мс					
CPU	14.8886	788.532	5958.03	47452.10	745217	-
$1\times1,32\times32$	36.4768	256.299	1145.10	8840.49	114357	-
$32\times32, 32\times32$	53.7845	287.704	932.85	4461.41	43472	411956
64×64, 32×32	99.7329	547.723	1513.98	6305.97	51747	466804
128×128, 32×32	284.3100	1559.010	3640.97	10970.80	73901	518470

Выводы

В ходе выполнения лабораторной работы я познакомился с параллельной реализацией метода Гаусса. При работе с матрицами сильно ощущается эффект распараллеливания, так как очень большое количество матричных операций имеют кубическую сложность.

Я наглядно убедился в важности объединения запросов к глобальной памяти — если его не происходит, время выполнения алгоритма увеличивается в 2-3 раза. Оптимальная конфигурация ядра: сетка блоков — 32×32 , сетка потоков — 32×32 .