МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Компьютерные науки и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №5
по курсу «Программирование графических процессоров»

Сортировка чисел на GPU. Свертка, сканирование, гистограмма.

Выполнил: В. В. Бирюков
Группа: 8О-407Б
Преподаватель: А. Ю. Морозов

Москва, 2022

Условие

Цель работы: Ознакомление с фундаментальными алгоритмами GPU: свертка (reduce), сканирование (blelloch scan) и гистограмма (histogram). Реализация одной из сортировок на CUDA. Использование разделяемой и других видов памяти.

Вариант: 6. Карманная сортировка с битонической сортировкой в каждом кармане.

Программное и аппаратное обеспечение

Характеристики графического процессора:

- Наименование: GeForce GT 545
- Compute capability: 2.1
- Графическая память: 3150381056 Б
- Разделяемая память на блок: 49152 Б
- Количество регистров на блок: 32768
- Максимальное количество потоков на блок: (1024, 1024, 64)
- Максимальное количество блоков: (65535, 65535, 65535)
- Константная память: 65536 Б
- Количество мультипроцессоров: 3

Характеристики системы:

- Процессор: Intel(R) Core(TM) i7-3770 CPU 3.40GHz
- Память: 15 ГБ
- HDD: 500 ГБ

Программное обеспечение:

- ОС: Ubuntu 16.04.6 LTS
- IDE: Visual Studio Code 1.72
- Компилятор: nvcc 7.5.17

Метод решения

Карманная сортировка сортирует массив путем распределения его по карманам, и сортировки каждого кармана по отдельности. Разделение по карманам осуществляется в два этапа: сначала массив распределяется по маленьким карманам (распределение происходит из предположения, что данные распределены равномерно), затем маленькие карманы объединяются в большие, к которым непосредственно применяется другой алгоритм сортировки. Размер большого кармана выбирается таким образом, чтобы его можно было отсортировать в разделяемой памяти. Если карман получился больше нужного размера, к нему рекурсивно применяется алгоритм с самого начала.

Для распределения элементов по карманам необходимо знать минимум и максимум в массиве, которые можно найти алгоритмом редукции. Перегруппировка массива в соответствии с карманами есть ни что иное, как модифицированная сортировка подсчетом, поэтому ее так же можно выполнить при помощи алгоритма гистограммы и алгоритма scan для суммы. Сортировка больших карманов осуществляется битонической сортировкой.

Сложность работы карманной сортировки в среднем линейная. Наилучшие результаты достигаются если числа в массиве равномерно распределены.

Описание программы

Программа разбита на заголовочные файлы, соответствующие основным алгоритмам — редукции, scan, алгоритму гистограммы, битонической сортировки и карманной сорти-

ровки. Файл `utils.hpp` содержит дополнительные математические и вспомогательные функции.

Реализация редукции и scan позволяет использовать их вместе с любой бинарной функцией, однако в C++11 это не очень удобно делать, из-за отсутствия шаблонов переменных. Битоническая сортировка реализована полностью, для работы с массивом любой длины, хотя используется только для сортировки в разделяемой памяти.

Редукция использует все основные оптимизации, кроме развертки цикла; scan реализован без оптимизаций, кроме использования фиктивных элементов; алгоритм гистограммы всегда строит ее в глобальной памяти; битоническая сортировка оптимизирована для небольших массивов и не дополняет их до степени двойки в глобальной памяти — это значительно уменьшает время работы карманной сортировки.

Результаты

Анализ программы профилировщиком

Размер тестового файла: 10^8, конфигурация ядер: 128×1024.

```
Profiling result:
Time(%)      Time   Calls       Avg       Min       Max  Name
 78.63%  6.02814s   99315  60.697us  59.362us  61.570us  void
   bitonic_sort_shared_memory<float>
  9.05%  693.59ms       1  693.59ms  693.59ms  693.59ms  void group<float>
  6.01%  460.67ms       1  460.67ms  460.67ms  460.67ms  void histogram<uin32_t,
   uin32_t>
  3.39%  260.19ms       6  43.365ms  2.6950us  130.05ms  void reduce<float>
  1.41%  108.41ms       3  36.136ms  22.140ms  64.096ms  [CUDA memcpy HtoD]
  0.88%  67.743ms       7  9.6776ms  2.8480us  65.610ms  [CUDA memcpy DtoH]
  0.44%  33.688ms       1  33.688ms  33.688ms  33.688ms  void split<float>
  0.16%  12.610ms       2  6.3050ms  15.802us  12.594ms  void scan<uin32_t>
  0.01%  906.58us       2  453.29us  2.4790us  904.10us  void per_block_func<uin32_t>
  0.01%  516.76us       2  258.38us  2.3680us  514.39us  [CUDA memset]
  0.00%  14.210us       5  2.8420us  2.6250us  3.1680us  [CUDA memcpy DtoD]
  0.00%  14.191us       1  14.191us  14.191us  14.191us  void scan<uin32_t>
```

Больше всего ожидаемо выполняется битоническая сортировка, вызванная примерно $\frac{10^8}{1024} = 97656$ раз.

```
Invocations                               Event Name         Min         Max         Avg
Device "GeForce GT 545 (0)"
   Kernel: void scan<uin32_t>(uin32_t*, uin32_t (*) (uin32_t, uin32_t))
     1                    l1_shared_bank_conflict           0           0           0
     1                           divergent_branch           0           0           0
   Kernel: void per_block_func<uin32_t>(uin32_t*, uin32_t*, int, uin32_t (*) (uin32_t,
    uin32_t))
     2                    l1_shared_bank_conflict           0           0           0
     2                           divergent_branch           0           0           0
   Kernel: void histogram<uin32_t, uin32_t>(uin32_t*, int, uin32_t*)
     1                    l1_shared_bank_conflict           0           0           0
     1                           divergent_branch           0           0           0
   Kernel: void group<float>(float*, float*, int, uin32_t*, uin32_t*)
     1                    l1_shared_bank_conflict           0           0           0
     1                           divergent_branch           0           0           0
   Kernel: void reduce<float>(float*, int, float*, float (*) (float, float))
     6                    l1_shared_bank_conflict           0           0           0
     6                           divergent_branch           0           0           0
   Kernel: void scan<uin32_t>(uin32_t*, int, uin32_t*, uin32_t (*) (uin32_t, uin32_t))
     2                    l1_shared_bank_conflict           0           0           0
     2                           divergent_branch           0           0           0
   Kernel: void bitonic_sort_shared_memory<float>(float*, int, int, float)
 99315                    l1_shared_bank_conflict           0           0           0
 99315                           divergent_branch        1143        1499        1425
   Kernel: void split<float>(float*, uin32_t*, int, int, float, float)
     1                    l1_shared_bank_conflict           0           0           0
     1                           divergent_branch           0           0           0
```

От конфликтов банков разделяемой памяти удалось избавиться во всех алгоритмах, где она используется. Дивергенция потоков наблюдается только в битонической сортировке, вероятно это связано с тем, что на каждой итерации активна только часть потоков.

Сравнение времени работы

Размер теста	100	1000	10^4	10^5	10^6	10^7	10^8
Конфигурация	**Время выполнения, мс**						
CPU	0.0556	0.6301	5.9759	58.623	599.690	5913.16	65898.06
128×128	0.3141	0.9337	3.1465	23.631	220.344	2279.35	22634.16
128×512	0.4731	0.8130	1.6202	10.287	87.063	949.79	9346.23
128×1024	0.5211	0.8248	1.5834	9.617	79.065	869.78	8519.17
256×1024	0.5704	0.8861	1.6135	9.657	79.278	870.03	8534.99
512×1024	0.6647	0.9807	1.7309	9.779	79.598	871.51	8523.13
1024×1024	0.8734	1.1977	1.9291	9.970	79.859	872.14	8519.02
Битоническая сортировка							
128×1024	0.0385	0.0841	0.8510	8.019	75.615	1538.61	15307.46

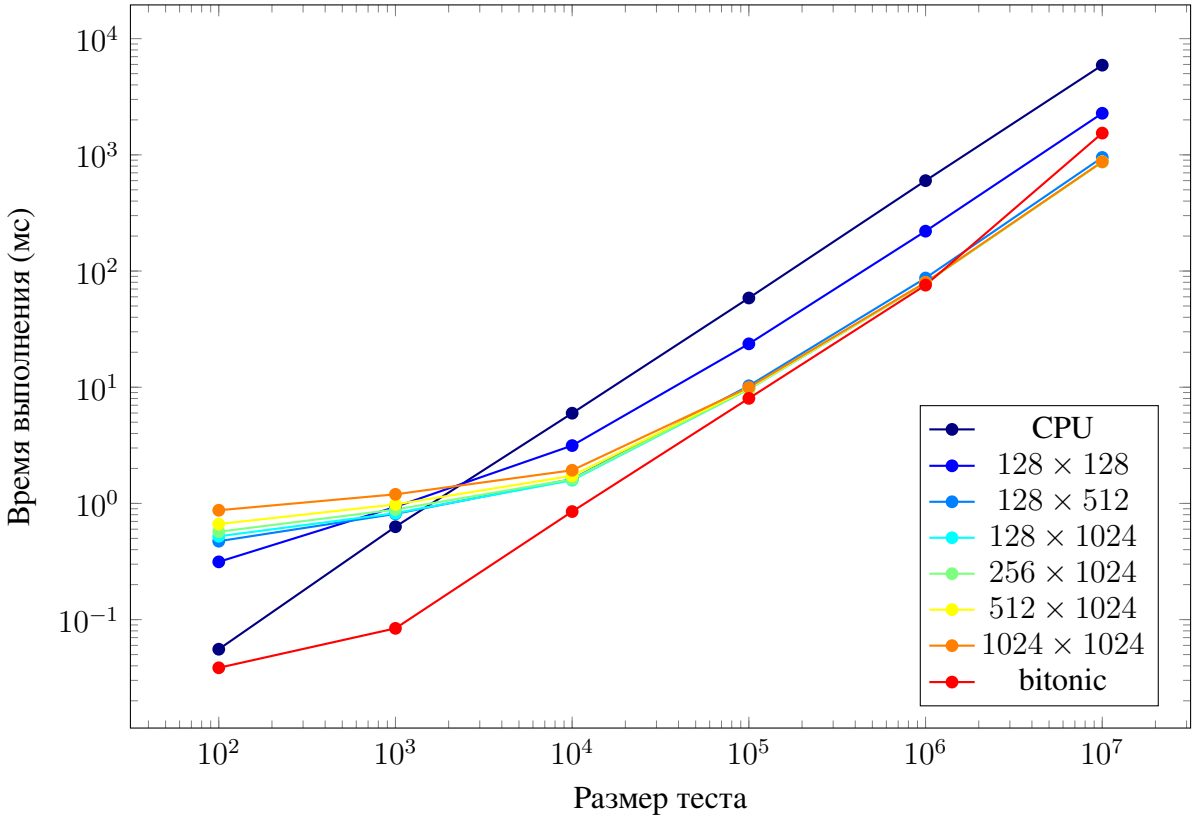

Из замеров видно, что уменьшение числа потоков, от которого зависит количество элементов, обрабатываемых в разделяемой памяти, значительно увеличивает время работы. Слишком большое число потоков — тоже, но не так существенно, оптимальная конфигурация: 128×1024. Сортировка на CPU быстрее на маленьких тестах, но после 1000 элементов начинает сильно проигрывать. Так как битоническая сортировка была реализована полностью, я решил сравнить еще и с ней. На маленьких тестах она работает быстрее всего, но, начиная с 10^7 — в два раза медленнее карманной.

Выводы

В ходе выполнения лабораторной работы я познакомился с параллельной реализацией некоторых линейных алгоритмов и сортировок. Распараллеливание таких алгоритмов дает очень хорошие результаты, однако реализовывать их гораздо сложнее.

Во время тестирования алгоритмов было очень хорошо заметно влияние различных оптимизаций, и то, как конфликты в разделяемой памяти или лишнее выделение памяти могут негативно сказаться на времени работы.